

Техническая документация для аналитического планирования поставок

Проект представляет собой веб-приложение, предназначенное для автоматизации расчета оптимального объема закупок. Интерфейс вычисляет локальные и сетевые метрики ошибок, визуализирует временные ряды и формирует суточные планы поставок. Проект контейнеризирован с помощью Docker для быстрого развертывания.

1 Архитектура интерфейса и сценарии работы

Пользователь взаимодействует с системой через интерактивный веб-интерфейс в браузере. В боковой панели управления выбираются параметры аналитики (горизонт, алгоритм) и конкретный объект (номер магазина, категория товара). Приложение мгновенно пересчитывает показатели, строит сводный график временного ряда с историей и прогнозом, а также генерирует таблицы суточной потребности на соответствующих вкладках. Процесс полностью автоматизирован.

2 Выбор пользователя

Система предоставляет гибкие динамические фильтры для глубокого анализа цепочки поставок:

- **Горизонт прогноза** — выбор периода планирования (например, 16 дней) для подстройки под логистический цикл.
- **Алгоритм прогнозирования** — переключение между тремя заложенными в ядро моделями: XGBoost, CatBoost и нейросетью LSTM.
- **Объект анализа** — каскадные списки номеров магазинов (`store_nbr`) и товарных групп (`family`), которые автоматически обновляются под выбранную конфигурацию.

3 Обработка данных

Процесс обработки данных и формирования бизнес-рекомендаций состоит из следующих этапов:

1. Загрузка Parquet-файла базы предрасчетов и кэширование данных через декоратор `@st.cache_data`.
2. Выделение глобального среза сети по выбранному горизонту и модели для расчета сетевого бенчмарка точности.
3. Фильтрация локальных данных под конкретный магазин и товар.
4. Очистка прогнозов от отрицательных значений и расчет суммарного объема закупки по формуле:

$$\text{Total Demand} = \left\lceil \sum_{i=1}^n \max(0, \hat{y}_i) \right\rceil \quad (1)$$

5. Расчет локальных метрик ошибок (WAPE, MAE, RMSE) и их сопоставление с сетевыми.
6. Отрисовка графиков динамики спроса через `st.line_chart` и генерация пошагового плана поставок.

4 Поддерживаемые форматы и ограничения

- **Входной формат:** Файл `precomputed_predictions.parquet` (использование PyArrow/FastParquet для ускорения ввода-вывода).
- **Временные ряды:** Колонка `date` принудительно трансформируется в формат `datetime64` для корректного построения осей графиков.

Ограничения:

- Расчет коэффициента детерминации R^2 требует наличия минимум 2 точек в тестовом периоде.
- При расчете ошибки WAPE заложена программная защита от деления на ноль на случай дней с абсолютно нулевыми продажами.

5 Техническое описание компонентов

- `app.py` — основной скрипт веб-интерфейса на Streamlit. Содержит логику реактивной фильтрации, расчет математических метрик ошибок с помощью `scikit-learn`, отрисовку бизнес-панели, графиков и табличных вкладок.
- `generate_predictions.py` — фоновый скрипт пайплайна машинного обучения. Отвечает за загрузку сырых данных, обучение моделей (XGBoost, CatBoost, LSTM) и сохранение предсказаний в Parquet.
- `requirements.txt` — список Python-зависимостей с зафиксированными версиями для воспроизводимости (`streamlit`, `pandas`, `numpy`, `scikit-learn`, `pyarrow`).
- `Dockerfile` — инструкция для сборки легковесного Docker-образа на базе Python-runtime. Настраивает рабочее окружение и порты для веб-сервера.

6 Модели и данные

- **XGBoost / CatBoost** — градиентный бустинг над решающими деревьями, оптимизированный под табличные исторические данные, лаги и календарные признаки.
- **LSTM (Long Short-Term Memory)** — рекуррентная нейронная сеть, эффективно улавливающая сложные долгосрочные последовательности и волны сезонности в продажах.
- **Parquet Database** — оптимизированное колоночное хранилище. Содержит поля фактических продаж (y) и точечных прогнозов ($\hat{y}$) в разрезе признаков `store_nbr`, `family`, `horizon` и `data_type` (*history/test*).

7 Метрики валидации

Для оценки надежности моделей система в реальном времени рассчитывает следующие показатели качества:

Таблица 1: Математические метрики оценки моделей

Метрика	Формула расчета	Бизнес-смысл
WAPE	$\frac{\sum y_i - \hat{y}_i }{\sum y_i} \times 100\%$	Общая относительная ошибка в объемах
MAE	$\frac{1}{n} \sum y_i - \hat{y}_i $	Средняя абсолютная ошибка в штуках
RMSE	$\sqrt{\frac{1}{n} \sum (y_i - \hat{y}_i)^2}$	Штраф за критические промахи прогноза
R^2	$1 - \frac{\sum (y_i - \hat{y}_i)^2}{\sum (y_i - \bar{y})^2}$	Доля объясненной моделями дисперсии

8 Инфраструктура и развертывание

- **Платформа:** Локальный сервер или облачный инстанс (Ubuntu Server) с установленным Docker-движком.
- **Оркестрация:** Контейнеризация приложения Streamlit, изолирующая зависимости веб-интерфейса от среды разработки моделей.
- **Доступ:** Веб-интерфейс публикуется на стандартном порту 8501 и доступен внутри локальной сети компании или через настроенный обратный прокси-сервер (Nginx).